

Analiza și Predicția Succesului pe YouTube

-Proiect Machine Learning-

Morovan Paul-Alexandru

Cuprins

1	Introducere și Motivație	2
2	Descrierea Datelor și Contextul Proiectului	3
2.1	Sursa și Dimensiunea Setului de Date	3
2.2	Definirea Caracteristicilor și Curățarea Datelor	3
2.3	Dicționarul de Date și Justificarea Variabilelor	3
2.4	Analiza Exploratorie a Datelor (EDA)	4
2.5	Formularea Problemei de Machine Learning	6
3	Aspecte Teoretice (State-of-the-Art)	7
3.1	Algoritmi Predictivi de Bază	7
3.2	Metode Avansate de Tip Ansamblu (Ensemble Learning)	7
3.3	Învățarea Bazată pe Instanțe	8
3.4	Analiza Critică a Modelelor: Avantaje și Limitări	8
4	Implementarea	9
4.1	Curățarea și Pregătirea Datelor	9
4.2	Împărțirea Setului de Antrenare și Testare	9
4.3	Optimizarea Hiperparametrilor (Grid Search)	9
4.4	Asigurarea prin Validare Încrucișată (Cross-Validation)	9
5	Testare și Validare	10
5.1	Metricile de Evaluare	10
5.2	Compararea Performanțelor Modelelor	10
6	Rezultate și Discuții	12
6.1	Analiza Factorilor de Influență (Feature Importance)	12
6.2	Analiza Comportamentală: De ce distribuția domină aprecierea?	13
7	Concluzii și Cunoștințe Noi	13
7.1	Concluziile Proiectului	13
7.2	Cunoștințe Noi Dobândite	14

1 Introducere și Motivație

Punctul de plecare al acestui proiect a fost pur și simplu timpul pe care îl petrec pe YouTube. Urmărind constant creatori de conținut cu audiențe foarte diferite, am ajuns să mă întreb ce anume face diferența între un clip care adună milioane de vizualizări și unul care abia trece de câteva mii. Există, evident, o mulțime de factori vizibili, cum ar fi nișa sau publicul țintă. Totuși, pe mine m-a interesat mai mult mecanismul ascuns al platformei. Mai exact, modul în care algoritmul decide pe cine promovează și pe cine ignoră.

Aproape orice vlogger își încheie clipurile cerând publicului un like, un share sau o abonare la canal. Scopul meu a fost să testez această regulă nescrisă a platformei. Am vrut să aflăm pe baza unor date reale care dintre aceste interacțiuni atârână cel mai greu la generarea de trafic.

Pentru creatori, vizualizările se traduc direct în venituri din reclame și contracte de sponsorizare. Dacă un model matematic poate estima traficul final al unui videoclip analizând doar primele reacții ale publicului, asta schimbă complet modul în care un canal își poate planifica strategia. Proiectul de față este exact o astfel de încercare practică de a decoda felul în care YouTube validează conținutul.

2 Descrierea Datelor și Contextul Proiectului

2.1 Sursa și Dimensiunea Setului de Date

Pentru a antrena modelele, am avut nevoie de un set de date masiv. Am pornit de la un dataset public de pe Kaggle care conține inițial peste un milion de înregistrări cu statistici globale de pe YouTube. Lucrul cu un milion de rânduri consumă însă enorm de multe resurse și timp de procesare. Așa că am decis să extrag un eșantion reprezentativ de 5.000 de videoclipuri. A fost o decizie pur practică. Am obținut suficiente date pentru ca algoritmul să învețe tipare complexe, dar am păstrat flexibilitatea de a rula și testa mai multe modele fără să blochez calculatorul.

2.2 Definirea Caracteristicilor și Curățarea Datelor

Datele brute au trecut printr-un proces inițial de curățare. Am eliminat valorile lipsă și duplicatele pentru a nu distorsiona antrenarea. Caracteristicile principale (**features**) pe care le-am folosit ca date de intrare sunt numărul de aprecieri (likes), numărul de comentarii, distribuiri (shares) și scorul de sentiment calculat pe baza textelor din comentarii. Variabila țintă (**target**), adică ceea ce încercăm să prezicem, este numărul total de vizualizări.

Pentru a oferi o perspectivă mai clară asupra formatului datelor, Tabelul 1 ilustrează un scurt extras din eșantionul final, după procesare.

Aprecieri	Comentarii	Distribuiri	Scor Sentiment	Vizualizări (Target)
12450	340	120	0.85	145000
850	45	12	0.60	12500
45200	1200	3400	0.92	850000
120	5	0	0.45	1050
3100	150	45	0.78	42000

Tabela 1: Extras din setul de date utilizat pentru antrenarea modelelor

2.3 Dicționarul de Date și Justificarea Variabilelor

Pentru a construi un model predictiv, a fost necesară o selecție a variabilelor de intrare. Fiecare caracteristică reținută în setul de date final reprezintă un anumit tip de comportament al utilizatorului pe platforma YouTube. În continuare, este prezentată justificarea teoretică și tehnică pentru includerea fiecărei variabile în procesul de învățare automată:

- **Numărul de aprecieri (likes):** Reprezintă cea mai comună formă de validare digitală. Este un indicator direct al calității percepute a conținutului. Din punct de vedere matematic, ne așteptăm ca un număr mare de aprecieri să coreleze pozitiv cu

vizualizările, servind ca un semnal de încredere atât pentru utilizatori, cât și pentru algoritmul de recomandare al platformei.

- **Numărul de distribuiri (shares):** Această variabilă măsoară potențialul viral al unui videoclip. Spre deosebire de o simplă apreciere, acțiunea de a distribui conținutul (pe rețele de socializare, aplicații de mesagerie etc.) necesită un efort conștient mai mare din partea utilizatorului. Includerea acestei variabile ne permite să evaluăm dacă propagarea externă a link-ului este un motor mai puternic de trafic decât interacțiunea internă.
- **Numărul de comentarii (comments):** Comentariile reflectă nivelul de dezbatere și comunitate pe care un videoclip îl generează. Un volum ridicat de comentarii indică un conținut provocator sau extrem de interesant, capabil să determine utilizatorul să petreacă timp scriind un text, un indicator critic pentru retenția pe platformă.
- **Scorul de sentiment (sentiment_score):** Aceasta este o caracteristică avansată, extrasă prin tehnici de procesare a limbajului natural (NLP) aplicate asupra textelor din comentarii. Scorul variază de la -1 (comentarii extrem de negative, critici, raportări) la +1 (comentarii extrem de pozitive, laude, susținere). Justificarea includerii sale rezidă în ipoteza că nu doar numărul brut de interacțiuni contează, ci și încărcătura emoțională a comunității; un videoclip controversat (cu sentiment negativ) ar putea genera trafic diferit față de unul apreciat unanim.
- **Durata videoclipului (duration_sec):** Exprimată în secunde, această variabilă ne ajută să înțelegem dacă lungimea materialului influențează decizia algoritmului de a-l propulsa în feed-ul utilizatorilor. Platforma tinde să recompenseze videoclipurile care mențin utilizatorii conectați pentru perioade mai lungi de timp.
- **Rata de implicare (engagement_rate):** Este o caracteristică derivată, calculată prin raportul dintre suma totală a interacțiunilor (likes + comments + shares) și volumul estimat de expunere. Această rată normalizează datele, permițând algoritmului să compare corect un canal mic, dar cu o comunitate foarte activă, cu un canal gigant, dar cu interacțiuni pasive.

2.4 Analiza Exploratorie a Datelor (EDA)

Înainte de a trece la aplicarea algoritmilor, am vrut să înțeleg mai bine structura internă a eșantionului. Era important să mă asigur că nu antrenez modelul pe o singură nișă izolată.

Figura 1 ilustrează distribuția canalelor în funcție de tipul de conținut creat. Se observă o diversitate solidă, cu prezențe puternice în zone precum Educație, Muzică, Tech Reviews

și Gaming. Această varietate este crucială pentru proiectul de față. Ea garantează că modelul matematic va învăța tiparele de interacțiune valabile la nivelul întregii platforme, generalizând rezultatele indiferent de subiectul videoclipului.




Figura 1: Distribuția canalelor de YouTube din eșantion pe categorii de conținut

Pe lângă analiza categoriilor, am vrut să măsurăm puterea relațiilor liniare dintre variabilele numerice. Figura 2 prezintă matricea de corelație (Pearson) a setului de date. Acest instrument vizual confirmă intuitiv ipotezele inițiale. Se observă o corelație pozitivă între numărul de vizualizări și variabile precum distribuțiile (0.88) sau aprecierile (0.82). În același timp, se remarcă lipsa totală a unei corelații între durata videoclipului sau scorul de sentiment și volumul de trafic generat.




Figura 2: Matricea de corelație a caracteristicilor numerice din setul de date

2.5 Formularea Problemei de Machine Learning

Din punct de vedere tehnic, problema se încadrează în categoria învățării supervizate. Mai exact, vorbim despre o problemă de **regresie**. Nu am vrut ca algoritmul să împartă videoclipurile în categorii generice de tip „popular” sau „nepopular”. Vreau să estimeze o valoare numerică exactă. Oferindu-i datele inițiale de interacțiune, modelul trebuie să calculeze matematic un volum concret de trafic.

3 Aspecte Teoretice (State-of-the-Art)

Nu am ales algoritmi de predicție la întâmplare, ci am urmărit o progresie logică a complexității. Am pornit de la modele matematice clasice și am ajuns la tehnici avansate de tip ansamblu, pentru a observa exact cum se schimbă performanța când algoritmul capătă flexibilitate.

3.1 Algoritmi Predictivi de Bază

Primul model implementat este **Regresia Liniară Multiplă**. Este baza absolută în machine learning pentru problemele cu valori continue. Algoritmul încearcă să tragă o linie dreaptă prin norul nostru de date, minimizând distanța dintre estimarea sa și vizualizările reale. Matematic, relația este de forma $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \epsilon$, unde y reprezintă vizualizările, iar x sunt variabilele noastre (like-uri, comentarii, shares). Literatura de specialitate o consideră fundația analizei predictive, utilă mai ales când relația dintre date este liniară [1].

Totuși, datele din lumea reală rareori respectă o linie dreaptă perfectă. Așa că am trecut la **Arborii de Decizie (Decision Trees)**. Aici mecanismul este complet diferit. În loc de ecuații, algoritmul împarte repetat setul de date răspunzând la întrebări de tip „Da/Nu”. De exemplu: „Are clipul peste 10.000 de like-uri?”. Dacă da, îl trimite pe o ramură; dacă nu, pe alta, până ajunge la un număr estimat de vizualizări. Acest model poate prinde relații mult mai complexe, dar este recunoscut pentru tendința de a memora datele dacă nu i se limitează adâncimea [2].

3.2 Metode Avansate de Tip Ansamblu (Ensemble Learning)

Trecerea firească de la un singur arbore de decizie a fost către **Random Forest**. După cum îi spune și numele, algoritmul construiește o „pădure” întreagă de arbori de decizie, fiecare antrenat pe o bucată diferită din date. La final, toți arborii votează, iar rezultatul este media lor. Această tehnică corectează excelent acea problemă de memorare a datelor pe care o are un singur arbore [3].

Adevărata putere predictivă a venit însă odată cu **Gradient Boosting**. Spre deosebire de Random Forest, unde arborii sunt complet independenți, aici ei sunt construiți secvențial. Fiecare arbore nou este creat special pentru a corecta greșelile făcute de arborele dinaintea lui. Este un proces de învățare continuă din propriile erori. De altfel, literatura academică demonstrează că metodele de tip boosting sunt deseori cele mai performante pentru datele de tip tabelar [4].

3.3 Învățarea Bazată pe Instance

În final, am vrut să am și un termen de comparație dintr-o cu totul altă clasă de algoritmi. Așa că am inclus **K-Nearest Neighbors (KNN)**. Acesta nu construiește un model matematic complex în prealabil. Când primește un videoclip nou, pur și simplu caută în istoricul datelor cele mai asemănătoare vecini pe baza interacțiunilor și face media vizualizărilor acestora [5].

3.4 Analiza Critică a Modelelor: Avantaje și Limitări

Alegerea acestor algoritmi nu a fost lipsită de compromisuri. Pe parcursul cercetării și implementării, am observat rapid că nu există un „algorithm perfect”, ci doar modele mai bine sau mai slab adaptate la structura datelor. Prin urmare, am realizat o scurtă analiză critică a punctelor forte și a vulnerabilităților pentru fiecare tehnică utilizată:

- **Regresia Liniară:** Principalul său avantaj este transparența. Poți vedea exact ce greutate matematică primește fiecare variabilă. Totuși, limitarea sa majoră este rigiditatea: presupune din start că datele noastre cresc constant și proporțional, un fenomen care, în realitatea dinamică și adesea haotică a platformei YouTube, este destul de rar întâlnit.
- **Arborele de Decizie:** Este un model extrem de „uman” în modul de operare (un șir de întrebări logice). Se descurcă excelent cu datele neliniare, dar vine cu un defect pe care l-am observat la primele teste: tinde să „învețe pe de rost” datele de antrenament (fenomenul de overfitting), eșuând uneori să generalizeze corect când primește videoclipuri noi.
- **Random Forest:** Rezolvă elegant problema memorării prin crearea acelei „păduri” de arbori independenți. Este un algorithm extrem de robust, care nu este deraiat ușor de valorile extreme (outliers). Reversul medaliei este că devine un model de tip „cutie neagră” (black-box) – am pierdut abilitatea de a urmări cu ochiul liber traseul unei decizii individuale prin sute de arbori simultan.
- **Gradient Boosting:** Este modelul care a livrat cea mai bună acuratețe. Faptul că fiecare arbore nou învață exclusiv din greșelile predecesorului său îl face imbatabil pe date tabelare. Însă, acest nivel de performanță are un preț: consumă cele mai multe resurse de procesare și este extrem de sensibil la calibrarea hiperparametrilor. Fără procesul de optimizare manuală, performanța sa ar fi fost mult sub potențial.
- **K-Nearest Neighbors (KNN):** Un model extrem de util ca termen de comparație de bază. Pe măsură ce setul de date a crescut, limitările au devenit evidente: algorithmul devine lent, deoarece la fiecare predicție nouă trebuie să calculeze matematic distanța față de absolut toate celelalte videoclipuri din istoric pentru a găsi „vecinii”.

4 Implementarea

4.1 Curățarea și Pregătirea Datelor

Pentru partea practică a proiectului, am folosit limbajul Python și biblioteca **Pandas** pentru manipularea datelor. Primul pas a fost importarea setului de date brut și aplicarea filtrelor de curățare. Am eliminat valorile lipsă (NaN) și duplicatele, asigurându-mă că modelele nu vor învăța din zgomot statistic. Așa cum am menționat anterior, am limitat procesarea la un eșantion de 5.000 de înregistrări pentru a menține un echilibru între performanța învățării și timpul de execuție.

4.2 Împărțirea Setului de Antrenare și Testare

Înainte de a introduce datele în algoritmi, a trebuit să le separ. Variabila țintă, adică numărul de vizualizări, a fost izolată de restul caracteristicilor. Ulterior, am folosit funcția *train_test_split* din biblioteca **Scikit-Learn** pentru a împărți eșantionul. Am alocat 80% din date pentru antrenarea modelelor și am păstrat restul de 20% strict pentru testare. Această porțiune de testare acționează ca o simulare a realității, reprezentând date noi, pe care algoritmul nu le-a văzut absolut deloc în timpul învățării.

4.3 Optimizarea Hiperparametrilor (Grid Search)

După ce am rulat cele 5 modele în forma lor de bază, am observat că performanțele pot fi îmbunătățite. Pentru modelul câștigător, Gradient Boosting, am decis să nu mă limitez la setările implicite. Am implementat o tehnică de optimizare numită **Grid Search** combinată cu validare încrucișată (Cross-Validation).

Am definit un spațiu de căutare specific pentru trei parametri esențiali. Primul a fost numărul de arbori construiți (*n_estimators*), pentru care am testat valorile 50, 100 și 150. Al doilea parametru a reglat rata de învățare (*learning_rate*), testând pași de 0.05, 0.1 și 0.2 pentru a controla cât de agresiv corectează modelul erorile anterioare. În final, am limitat adâncimea maximă a arborilor (*max_depth*) la 3, 5 și 7, prevenind astfel memorarea excesivă a datelor de antrenament.

Algoritmul a parcurs exhaustiv toate combinațiile posibile. Folosind parametrul *cv=3*, fiecare configurație a fost testată și validată de trei ori pe sub-eșantioane diferite, asigurând astfel robustețea rezultatului final.

4.4 Asigurarea prin Validare Încrucișată (Cross-Validation)

Când am configurat procesul de optimizare Grid Search, o decizie tehnică esențială a fost implementarea parametrului *cv=3*, care activează validarea încrucișată (K-Fold Cross-

Validation). Am evitat antrenarea modelelor optimizate pe o singură împărțire fixă a datelor, deoarece exista riscul ca algoritmul să obțină un scor bun din pură coincidență (de exemplu, dacă, întâmplător, primea în setul de antrenare doar videoclipuri cu un tipar extrem de previzibil).

Prin metoda validării încrucișate, algoritmul a preluat porțiunea de 80% din date alocată învățării și a împărțit-o intern în 3 „felii” (folds) egale. Apoi, a iterat procesul de antrenare în modul următor: a învățat tiparele pe două felii și și-a testat imediat cunoștințele pe a treia. A repetat procesul de trei ori, rotind secțiunile, astfel încât fiecare bucată de date a ajuns să fie folosită exact o dată pentru validarea internă. Scorul de performanță reținut pentru fiecare combinație de parametri a fost, de fapt, media matematică a acestor 3 încercări independente.

Dincolo de codul în sine, această abordare mi-a oferit o garanție metodologică: m-am asigurat că performanța raportată la final nu reprezintă o anomalie statistică sau un fenomen de supra-învățare (overfitting), ci reflectă o capacitate reală și stabilă a modelului de a generaliza informația, indiferent de modul în care setul de date este amestecat.

5 Testare și Validare

5.1 Metricile de Evaluare

Pentru a măsura obiectiv performanța algoritmilor, am evitat acuratețea clasică, specifică problemelor de clasificare. Fiind o problemă de regresie, am ales două metrici fundamentale care arată clar cât de mult greșește modelul.

Prima este **Eroarea Absolută Medie (MAE - Mean Absolute Error)**. Am preferat MAE în locul altor metrici deoarece oferă o interpretare directă și liniară a greșelii, fiind mai puțin sensibilă la valorile extreme atipice [6]. Practic, MAE ne spune cu câte vizualizări se înșală algoritmul, în medie, la fiecare predicție.

A doua metrică utilizată este **Scorul R^2 (Coeficientul de Determinare)**. Acesta măsoară proporția din variația vizualizărilor care este explicată de variabilele noastre (like-uri, shares, comentarii). Un scor de 1.0 ar însemna o predicție absolut perfectă, în timp ce un scor de 0.0 arată că modelul nu este mai bun decât simpla ghicire a mediei vizualizărilor [7].

5.2 Compararea Performanțelor Modelelor

Am evaluat toate cele 5 modele pe setul de testare (cele 20% din date nevăzute anterior). Rezultatele brute sunt prezentate în Tabelul 2.

Model ML Testat	Scor R^2 (Acuratețe)	Eroare MAE (Vizualizări)
Gradient Boosting (Optimizat)	0.8614	2277.30
Random Forest	0.8524	2371.16
Regresie Liniara	0.8454	2549.02
K-Nearest Neighbors	0.8150	2553.21
Arbore de Decizie	0.7461	2961.62

Tabela 2: Performanța modelelor pe setul de testare, ordonate după scorul R^2

Datele arată clar superioritatea tehnicilor de tip ansamblu. Algoritmul Gradient Boosting s-a clasat pe primul loc, reușind să explice peste 86% din variația traficului. Eroarea sa medie (MAE) este cea mai mică, greșind cu aproximativ 2.277 de vizualizări per videoclip, o marjă excelentă având în vedere fluctuațiile masive de trafic de pe YouTube.

Pentru o vizualizare mai intuitivă a acestor rezultate, Figura 3 prezintă o comparație grafică între cele cinci modele. Se poate observa ușor atât supremația modelului Gradient Boosting în ceea ce privește acuratețea, cât și minimizarea semnificativă a erorii comparativ cu algoritmul de la coada clasamentului, Arborele de Decizie.




Figura 3: Comparație vizuală a modelelor: Scorul R^2 (stânga) și Eroarea MAE (dreapta)

6 Rezultate și Discuții

6.1 Analiza Factorilor de Influență (Feature Importance)

După identificarea modelului Gradient Boosting ca fiind cel mai performant, etapa următoare a constat în analizarea modului în care acesta ia deciziile. Am vrut să deschid „cutia neagră” a algoritmului pentru a înțelege exact pe ce se bazează predicțiile sale. Figura 4 prezintă graficul de importanță a caracteristicilor (Feature Importance), oferind un răspuns clar la una dintre întrebările fundamentale ale acestui proiect.




Figura 4: Gradul de influență a interacțiunilor asupra numărului de vizualizări

Rezultatele contrazic parțial credința populară conform căreia aprecierile (likes) sunt cel mai important indicator de performanță. Modelul a determinat că volumul de **distribuiri (shares)** este, de departe, cel mai puternic predictor pentru succesul unui videoclip. Acesta are o pondere de aproape 80% în decizia algoritmului matematic. Aprecierile se situează pe locul al doilea la o distanță considerabilă. În același timp, numărul de comentarii și scorul de sentiment calculat pe baza acestora au o influență aproape neglijabilă asupra traficului final.

Această ierarhie sugerează o logică de business foarte clară din partea platformei YouTube. Algoritmul valorizează enorm conținutul care determină utilizatorii să îl propage activ. Distribuirea este considerată forma supremă de validare a calității, deoarece aduce trafic nou și extinde audiența dincolo de abonații curenți ai canalului, ținând utilizatorii mai mult timp în ecosistem.

6.2 Analiza Comportamentală: De ce distribuirea domină aprecierea?

Rezultatul conform căruia acțiunea de a distribui un videoclip are o greutate predictivă covârșitoare în fața aprecierilor m-a determinat să analizez logica de business a platformei YouTube. La prima vedere, aprecierile sunt cel mai vizibil metric pentru succes, însă algoritmul diferențiază profund între tipurile de efort pe care le depune utilizatorul.

Aprecierea (like-ul) reprezintă ceea ce putem numi o *interacțiune pasivă*. Utilizatorul se află deja în interiorul ecosistemului YouTube, consumă conținutul și validează calitatea printr-un simplu click. Efortul cognitiv și fizic este minim. Deși utilă pentru antrenarea sistemului intern de recomandări, această acțiune rareori aduce utilizatori noi pe platformă.

În schimb, distribuirea (share) reprezintă o *interacțiune activă* și o validare socială supremă. Când un utilizator copiază link-ul și îl trimite pe WhatsApp, Facebook sau alte rețele externe, el își asumă calitatea acelui videoclip în fața propriului cerc de prieteni. Din perspectiva YouTube, acest comportament este inestimabil din două motive majore:

1. **Atragerea traficului extern:** Un share aduce adesea utilizatori din afara platformei înapoi în ecosistem, generând noi sesiuni de vizionare și, implicit, noi afișări de reclame.
2. **Gruparea profilurilor de audiență:** Algoritmul învață că persoana care a trimis link-ul și cea care l-a deschis au interese comune, putând astfel să rafineze mult mai bine recomandările viitoare pentru ambele profiluri.

7 Concluzii și Cunoștințe Noi

7.1 Concluziile Proiectului

Proiectul a demonstrat cu succes că estimarea traficului unui videoclip pe baza primelor reacții ale publicului este o problemă rezolvabilă folosind tehnici de învățare automată. Am pornit de la modele matematice de bază, precum Regresia Liniară, și am ajuns la tehnici de tip ansamblu. Algoritmul Gradient Boosting a obținut performanțe solide, reușind să explice peste 86% din variația datelor, cu o eroare medie (MAE) de aproximativ 2.277 de vizualizări.

Din punct de vedere practic, lucrarea oferă o perspectivă valoroasă pentru creatorii de conținut. Strategiile de creștere a unui canal ar trebui să pună accent pe crearea de materiale care provoacă utilizatorul să dea share, lăsând pe plan secund cerșitul clasic de aprecieri și comentarii.

7.2 Cunoștințe Noi Dobândite

Dincolo de rezultatele tehnice brute, acest proiect a marcat o tranziție de la simplul rol de consumator de videoclipuri la cel de analist capabil să înțeleagă mecanismele din spate.

Prima lecție importantă a fost legată de realitatea datelor. Informațiile extrase în stare brută sunt pline de erori și anomalii. Curățarea lor și pregătirea setului de lucru mi-au demonstrat că preprocesarea consumă adesea mai mult timp și atenție decât antrenarea efectivă a algoritmilor.

De asemenea, am înțeles în profunzime utilitatea optimizării hiperparametrilor. Implementarea tehnicii Grid Search mi-a arătat practic faptul că performanța unui model nu depinde doar de alegerea algoritmului corect. Depinde direct de o calibrare fină a modului în care acesta învață (controlând adâncimea arborilor și viteza de învățare).

În final, folosirea metricilor precum R^2 și MAE m-a învățat cum să evaluez complet și obiectiv un sistem inteligent, validând rezultatele matematic, nu doar pe baza intuiției.

Bibliografie

- [1] Hastie, T., Tibshirani, R., Friedman, J., *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009.
- [2] Quinlan, J. R., *Induction of decision trees*, Machine Learning, vol. 1, nr. 1, pp. 81-106, 1986.
- [3] Breiman, L., *Random Forests*, Machine Learning, vol. 45, nr. 1, pp. 5-32, 2001.
- [4] Friedman, J. H., *Greedy function approximation: A gradient boosting machine*, Annals of Statistics, pp. 1189-1232, 2001.
- [5] Cover, T., Hart, P., *Nearest neighbor pattern classification*, IEEE Transactions on Information Theory, vol. 13, nr. 1, pp. 21-27, 1967.
- [6] Willmott, C. J., Matsuura, K., *Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance*, Climate Research, vol. 30, pp. 79-82, 2005.
- [7] Wright, S., *Correlation and causation*, Journal of Agricultural Research, vol. 20, pp. 557-585, 1921.